

高斯判別分析 (Gaussian Discriminant Analysis, GDA) 是一種生成式學習演算法 (Generative Learning Algorithm)，主要用於解決分類問題。其核心思想是為每一個類別的資料分佈建立一個機率模型，而非直接學習類別之間的決策邊界。

GDA 的運作基於以下關鍵假設與步驟：

1. 核心假設：GDA 假設在給定類別 $y = k$ 的條件下，特徵向量 \vec{x} 的條件機率分佈

$p(\vec{x}|y = k)$ 服從一個多變量高斯分佈 (Multivariate Gaussian Distribution)。其數學表達式為：

$$p(\vec{x}|y = k) \sim \mathcal{N}(\vec{\mu}_k, \Sigma_k)$$

其中 $\vec{\mu}_k$ 是類別 k 的平均向量， Σ_k 是其協方差矩陣。在本作業中，我們採用的是 GDA 的一個特例，即線性判別分析 (Linear Discriminant Analysis, LDA)，它進一步假設所有類別共用同一個協方差矩陣 Σ 。

2. 模型學習 (訓練階段)：訓練 GDA 模型的目標是從訓練資料中估計出模型的參數。對於二元分類問題 ($y=0, 1$)，需要估計的參數包括：

- 類別先驗機率 (Prior Probability): $\phi = p(y = 1)$ ，通常由類別 1 樣本數在總樣本中的比例來估計。則 $p(y = 0) = 1 - \phi$ 。
- 類別平均向量 (Mean Vectors): $\vec{\mu}_0$ 和 $\vec{\mu}_1$ ，分別透過計算屬於類別 0 和類別 1 的所有樣本特徵的平均值得到。
- 共用協方差矩陣 (Shared Covariance Matrix): Σ ，透過計算所有樣本點相對於其所屬類別均值的協方差，並進行加權平均來估計。

3. 預測階段：對於一個新的輸入樣本 \vec{x}_{new} ，GDA 利用貝氏定理 (Bayes' Theorem) 計算其屬於每一個類別的後驗機率 (Posterior Probability)：

$$p(y = k|\vec{x}_{new}) = \frac{p(\vec{x}_{new}|y = k)p(y = k)}{p(\vec{x}_{new})}$$

模型最終會將 \vec{x}_{new} 預測為後驗機率最大的那個類別。由於分母 $p(\vec{x}_{new})$ 對所有類別是常數，因此預測規則簡化為最大化分子 $p(\vec{x}_{new}|y = k)p(y = k)$ 。在 LDA 的假設下，這會產生一個線性的決策邊界。

由於這個資料集（台灣本島）的資料點是類似一個橢圓的群集，所以GDA模型是可行的，準確性不至於太低。

建構 $h(x)$

組合函數的建構是基於一個條件化執行 (Conditional Execution) 的邏輯，其程式實現遵循以下步驟：

1. 建立函式框架：首先，定義一個函式 `predict_h_model`，該函式接收輸入特徵 X 、已訓練的分類模型 `C_model` 和迴歸模型 `R_model` 作為參數。
2. 執行分類作為閘門機制 (Gating Mechanism)：對於所有輸入的特徵向量，首先通過分類模型 `C_model` 進行預測。此步驟的輸出是一個標籤陣列 (包含 0 和 1)，它將作為後續操作的判斷依據。
3. 初始化預設輸出：建立一個與輸入樣本數相同大小的輸出陣列，並將所有元素初始化為 -999。此操作確保了所有被分類器判定為 0 的樣本，其最終輸出值都符合函數定義的第二個條件。
4. 選擇性執行迴歸：利用上一步驟生成的標籤陣列，建立一個布林遮罩 (Boolean Mask) 以篩選出所有被判定為 1 的樣本。接著，僅將這部分樣本的特徵傳遞給迴歸模型 `R_model` 進行預測，從而得到對應的溫度值。
5. 整合預測結果：最後，將迴歸模型產生的溫度預測結果，根據布林遮罩更新至初始化後的輸出陣列的相應位置。

